

DOI:10.13232/j.cnki.jnju.2024.04.005

基于卷积神经网络的 P300 脑电信号解码

夏 天, 李竞斌, 向程乐, 伏云发*

(昆明理工大学信息工程与自动化学院, 昆明, 650031)

摘 要: P300 拼写器是允许用户使用脑电图(Electroencephalogram, EEG)输入的脑机接口(Brain-Computer Interface, BCI)系统, 高传输、高准确率地检测 P300 信号对于提高 P300 拼写系统的性能非常重要。针对 P300 脑电信号特征提取方式信噪比低、识别困难等特点, 提出一种基于批量归一化和残差块的卷积神经网络(Convolutional Neural Network, CNN)模型, 可以在模型训练中保留重要特征的同时加快模型损失的收敛速度。采用分类精度、AUC(Area under Curve)、准确率、召回率、 F_1 -score 等指标来验证所提模型的有效性, 并与其他方法进行了对比实验。实验结果显示, 与传统的 CNN 算法相比, 所提模型的分类精度提升 6%, 损失函数的收敛速度也有提升; 与传统机器学习方法相比, 所提模型的各项评价指标都优于传统算法。证明该算法是提高 P300 拼写器性能的有效方法。

关键词: P300, 机器学习, 卷积神经网络, 脑机接口

中图分类号: TP18, R318, TN911.7

文献标志码: A

P300 EEG signal decoding based on a convolutional neural network

Xia Tian, Li Jingbin, Xiang Chengle, Fu Yunfa*

(School of Information Engineering and Automation, Kunming University of Science and Technology,
Kunming, 650031, China)

Abstract: The P300 speller, a brain-computer interface (BCI) system enabling users to input via electroencephalogram (EEG), plays a vital role in achieving high transmission and accuracy in detecting P300 signals to enhance the performance of P300 speller systems. To address such challenges as low signal-to-noise ratio and difficulty in feature extraction from P300 EEG signals, this study introduces a convolutional neural network (CNN) model incorporating batch normalization and residual blocks. This model aims to preserve critical features during training while expediting the convergence of the model's loss function. Performance evaluation of the proposed model and comparative algorithms is conducted using metrics such as classification accuracy, AUC, precision, recall and F_1 -score. Results indicate that compared to traditional CNN algorithms, the proposed model achieves a 6% increase in classification accuracy and exhibits improved convergence speed of the loss function. Furthermore, when compared to traditional machine learning methods, the proposed model outperforms across all evaluation metrics. Thus, this algorithm presents an effective approach for enhancing the performance of P300 speller systems.

Key words: P300, machine learning, CNN, BCI

脑机接口(Brain-Computer Interface, BCI)是一种变革性的人机交互技术^[1]。P300-BCI (P300-Based Brain-Computer Interface)拼写器是一种依

靠受试者对特定刺激识别后脑活动产生的 P300 电生理信号进行交互的反应型 BCI 技术, 但 P300 对小概率事件的依赖程度高, 需要在实验环境中

基金项目: 国家自然科学基金(62376112, 82172058)

收稿日期: 2024-04-22

* 通讯联系人, E-mail: fyf@ynu.edu.cn

给予受试者目标刺激和偏差刺激^[2]。

研究发现,大脑的不同区域均会被诱发产生不同幅值的 P300 信号^[3],表明受试者在应对特定刺激时存在特征差异。因为 P300 信号存在通道间的特征差异以及信噪比低、模型训练困难等问题^[4-5],所以后期对 P300 信号的特征提取和模型选择是解码的关键。以往的 P300 特征主要是顶叶和枕叶脑区的时域特征^[6],如波形振幅、潜伏期等,通常采用人工方法来提取,然而,由于周围环境和受试者的可变性,人工提取的特征无法有效地表征信号^[7]。传统的解码模型大都基于非空间信息的算法进行分类^[8],如线性判别分析、支持向量机、黎曼几何等。由于 P300 信号是非线性非平稳信号,传统的线性分类器无法充分捕捉数据中的非线性关系,并且在分类前需要进行繁杂的数据预处理工作,对数据质量要求较高。黎曼几何分类器需要调优的参数较多,增加了算法的复杂性,算法的解码能力不佳。这些算法忽略了空间特征和非线性关系,为了提升解码性能,研究人员提出了一系列基于空间信息的解码算法^[9],如空间滤波器^[10]、区间 ERP 判别分析^[11]等,但这些解码算法也存在一些局限性。空间滤波器在处理时域特征潜伏期抖动较大的情况下,表现不理想;区间 ERP 判别分析涉及对协方差矩阵的计算和处理,会极大地消耗计算机的性能,使模型训练效果不佳且收敛速度缓慢。为了进一步提升模型的解码能力,研究人员将不同类型的深度学习算法运用于 P300 脑电解码,如 EEGnet^[12]、Shallow-ConNe^[13]和 P3Net^[14]等,这些深度学习算法考虑了通道数据中的空间特征和非线性关系,在一定程度上提高了分类精度,但存在网络较浅和对事件相关电位中的其他成分不敏感等问题,限制了它们在实用场景中的解码表现。一种能够有效提取多通道和多尺度特征并增强 P300 信号的深度学习算法会具有更好的解码性能,将极大地提高对 P300 信号的解码能力。

卷积神经网络(Convolutional Neural Network, CNN)可以从原始数据中自动提取多域特征^[15],尤其对空间特征比较敏感且在特征提取前无需进行繁琐的数据预处理^[16]。Völker et al^[17]使用 CNN 和正则化线性判别分类器来解码 31 名被

试的 P300 信号, CNN 的平均准确率为 84.1%, 明显优于机器学习模型。Li et al^[18]设计了 CNN 结合主成分分析的模型,采用主成分分析进行降维,再应用改进的 CNN 模型对 P300 信号进行解码,得到的最高准确率为 93%。这些基于深度学习的解码模型已经取得了一定成果,但仍不能高准确率地解码 P300 信号,表现为采用手工提取特征、参数复杂,所以在构建解码模型时需要不断调整模型结构和超参数范围,加重了研究负担。分支结构中的残差设计是提高解码模型灵活性的有效方法,而上述解码模型都是单分支结构,缺乏灵活性和适应性。多分支结构可以选择性地关注相关脑电信息并调整不同特征,增强模型的解码性能。批量归一化通过规范化特征分布,有助于模型处理数据,其改善了网络的优化过程,允许采用更高的学习率,加速收敛速度,同时减少了模型对初始权重的依赖,使模型能够更有效地从数据中学习特征,不会因初始差异而导致模型训练不稳定。

本研究提出一种基于批量归一化和残差块的 CNN 模型 GNRBNet,在检测 P300-BCI 系统中的 P300 信号时^[19],可以从多尺度的空域、时域中提取 P300 信号的特征^[20],从数据中抽象出更一般性的脑电特征,同时保持对特定特征的敏感性,实现丰富的特征学习、多样化的残差分配和多层次的数据训练。

1 材料

1.1 实验数据 实验期间共招募 10 名健康受试者,均为在校研究生,对 P300 有一定了解,平均年龄 25 岁。研究得到了昆明理工大学医学伦理委员会的批准,所有受试者在实验开始前均已知晓实验目的和实验流程并签署了知情同意书。采用 Neuracle 64 通道的 EEG 采集设备 NSW364(中国常州博睿康科技股份有限公司)记录实验数据,采样率为 1000 Hz。实验范式是经典的 5×5 的单目标 P300 刺激字符矩阵^[21],如图 1 所示。

实验包含一个 session,由三个 run 组成,每个 run 之间有 2~5 min 的休息时间;每个 run 包含两个 block,一个 block 包含 25 个 trials。第一个 trial 开始前有 1 s 的准备时间,每个 trial 开始时随机呈现一个倒三角形指向的字母作为靶字母,持续时




图1 5×5的单目标P300刺激范式

Fig. 1 5×5 single-target P300 stimulus paradigm

间为0.5 s,提示结束后有0.5 s的休息. 然后进入行/列闪烁期,先随机闪烁行,后随机闪烁列,行/列闪烁持续时间为0.3 s,共有10种行/列闪烁状态,持续时间共计3 s,其中两个行和列闪烁包含靶字母(偏差刺激),八个行和列闪烁不包含靶字母(标准刺激). 闪烁结束后有1 s的休息时间,然后继续下一个 trial. 随后算法对P300响应进行解码,识别出目标闪烁字符所在的行和列^[22]. 每个 trial的时序如图2所示. 在随机的行/列闪烁过程中,包含偏差字符(受试者不需要注意的字符)的行/列的概率为4/5,其他目标字符(需要注意的字符)的概率为1/5. 目标字符的出现是小概率事件,足以诱发P300电位.




图2 范式时序图

Fig. 2 Paradigm timeline diagram

1.2 数据预处理 EEG预处理步骤如下:(1)根据事件的标签信息创建具有标签的原始数据;(2)目视检查,剔除有明显伪迹和损坏的通道数据,对数据进行独立成分分析,确定包含伪迹的独立成分并剔除;(3)使用0.1~30 Hz带通滤波器进行带通滤波;(4)对连续记录的EEG数据进行分段,以刺激出现时为0 ms,提取-100~600 ms的EEG数据,得到多个时段数据;(5)基线校正的时间窗选取-100~0 ms,以消除信号相对于基线的偏离;(6)剔除绝对值大于75 μV 的噪声信号,同时将每一个时段数据从1000 Hz下采样至160 Hz;(7)对所有时段进行通道和试次的叠加平均,得到P300响应数据^[23].

2 方法

2.1 所提模型方法 本文提出的GNRBNet算法是将批量归一化方法(GN)、残差方法(RB)相结合的多层CNN算法,模型架构如图3所示.

模型第一层为输入层,GN在该层对原始脑电图数据进行归一化,使输入数据呈现零均值和单位方差的正态分布. 第二层至第六层的卷积层通过卷积核对P300输入数据进行特征提取,提取与目标事件相关的局部空间特征,同时加入GN与RB,使每次卷积后的神经元激活值再次恢复到零均值和单位方差的正态分布. 第七层为全连接层和Dropout丢弃层,丢弃层的作用是防止模型过拟合,同时保留足够的信息来训练稳健的模型,参数经过模型调优最终选择0.5. 第八层为Sigmoid激活函数.




图3 GNRBNet算法的模型架构

Fig. 3 Model architecture of GNRBNet

由于P300数据的样本特征不平均,GN可以在模型输入时对数据进行减去均值并除以方差的操作,使数据移动到更小范围的中心区域,解决特征差异导致的数据分散问题. 中心区域是模型梯度高的区域,在层中添加GN能够有效地对抗梯度消失的问题. 在训练过程中,随着前一层参数的变化,后续每一层的输入分布都会发生变化,使网络训练变得复杂,如果不能把经过减均值除方差操作得到的正态分布假设为最能体现训练样本特征的最佳分布,可能存在无法将数据聚拢到中心区域的情况,导致模型性能下降. 为此,GN引入缩放和移动步骤来减轻内部协变量偏移,即尺度变换和偏移,使数据的分布更贴近真实数据分

布,保证模型的非线性表达能力.GN的核心是优化均值和方差的变换,具体地,将训练数据划分为小批量,对每个训练小批量进行归一化.在该环节中,首先计算平均值和方差,计算如式(1)和式(2)所示,其中, m 表示批量大小, X_j 表示批量中的每个样本:

$$P_{\text{mean}} = \frac{1}{m} \sum_{j=1}^m X_j \quad (1)$$

$$F_{\text{variance}} = \frac{1}{m} \sum_{j=1}^m (X_j - P_{\text{mean}})^2 \quad (2)$$

随后,对P300数据进行标准化和方差处理. ϵ 为最小非零误差,如式(3)所示:

$$\hat{X}_i = \frac{X_i - P_{\text{mean}}}{\sqrt{F_{\text{variance}} + \epsilon}} \quad (3)$$

最后,通过变换计算 α 和 β ,如式(4)和式(5)所示:

$$GN_{\alpha,\beta}(X_i) = Q_i \quad (4)$$

$$Q_i = \alpha \hat{X}_i + \beta \quad (5)$$

模型的RB可解决多层CNN的各层结构之间可能出现的数据问题.构建CNN结构时,由于存在多个层操作,引入RB的目的是将模型输入数据的一部分直接连接到输出数据.RB关注每一层结构的输入和输出之间的差异,可以防止原始输入数据在经过层操作后丢失重要特征.在引入RB时,不跨越CNN两层之间的结构,仅在单独的某一层使用,这种设计有助于在增加网络深度的情况下,RB也能更好地协助模型学习特征.在处理特征分布不均匀的P300数据时,RB的作用是在层结构处理输入和输出数据时,尽可能地保留一些提取过的多尺度动态特征,通过特征重用,网络能更好地利用已学到的特征,减少特征差异大而导致的训练困难和梯度消失问题,使模型具有更深的层结构,从而能够学习多尺度特征,提高整体性能.密集连接层在卷积和池化层之后进行分类任务,其作用是将前面层提取的特征进行非线性变换和组合,帮助模型学习更抽象的特征,得到更具判别性的特征表示,然后输出到最终的输出层进行分类.

2.2 对比模型方法 在预处理阶段,首先提取P300数据的协方差特征并输入主流的机器学习算法进行分类实验,与GNRBNet模型进行对比.

第一个对比算法采用协方差矩阵来捕捉脑电信号在特定刺激事件期间的相关性,随后将事件相关协方差矩阵转换到切线空间以获得线性可分性,最后,根据转换后的切线空间数据使用逻辑回归模型进行分类^[24].区间ERP分析的核心在于利用ERP的区间模型来克服实验期间的差异性,通过自动分析空间域内的感兴趣区域并对更多判别信息的通道赋予更大的权重来实现.

第二个对比算法也采用协方差矩阵来捕捉脑电信号在特定刺激事件期间的相关性,得到脑电信号的事件相关协方差矩阵后,结合黎曼几何分类器来进行分类^[25].黎曼几何分类器的核心在于利用黎曼流形的特性和度量来对高维数据进行分类,尤其适用于处理具有复杂相关性结构的数据,如脑电信号的协方差矩阵.

第三个对比算法采用空间滤波器Xdawn进行P300特征增强和滤波^[26],并使用正则化LDA寻找最佳投影方向.设找寻到的最佳投射向量为 X ,使得在投影后的空间中不同类别之间的距离最大化,同时类内方差最小化.令 Q_K 代表P300与非P300两类样本, $K=0$ 为P300样本, $K=1$ 为非P300样本, Σ_K 为所代表样本的协方差向量, L_K 为样本的均值数, X 为最佳投射向量,通过判别向量来计算 $J(M)$ 的最大值.如式(6)所示:

$$J(M) = \frac{X^T S_b X}{X^T S_w X} \quad (6)$$

其中,类内散度矩阵 S_w 以及类间散度矩阵 S_b 通过式(7)和式(8)求取:

$$S_w = \sum_0 + \sum_1 \quad (7)$$

$$S_b = (L_0 - L_1)(L_1 - L_0)^T \quad (8)$$

其中, L_0 与 L_1 代表P300与非P300两类样本的均值, Σ_K 为两类样本的协方差向量.

求取LDA目标函数,如式(9)所示:

$$M = \operatorname{argmax}_w \frac{\operatorname{tr}(X^T S_b X)}{\operatorname{tr}(X^T S_w X)} \quad (9)$$

第四个对比算法采用空间滤波器Xdawn结合黎曼几何分类器进行P300响应分类,其基本思想是应用空间滤波器来增强相关特征并最大化信噪比,使用黎曼几何分类器在经过空间滤波器增强的信号上进行训练.空间滤波器基于对脑电信号的协方差矩阵进行分析和变换,将P300信号从

噪声中分离出来,以提取与特定刺激事件相关的脑信号成分,使后续的分析更加准确和可靠. 空间滤波器的计算流程如下:设 D 为原始 EEG 数据, Z 为伪迹噪声, T 为 Toeplitz 矩阵,处理后的 EEG 数据 A 的计算如式(10)所示:

$$A = TD + Z \quad (10)$$

Xdawn 滤波器 $\hat{W}$ 的计算如式(11)所示:

$$\hat{W} = \operatorname{argmax}_W \frac{\operatorname{Tr}(W^T D^T T^T T W)}{\operatorname{Tr}(W^T A^T A W)} \quad (11)$$

其中, argmax_W 表示使用广义瑞利熵对最优滤波器 W 求取最大化信噪比, $\hat{W}$ 表示对计算所得的结果进行最大化取值.

第五种对比算法为经典 CNN 模型,其由卷积层、激励层、池化层和全连接层四种结构组成. 实验中用来和所提模型进行消融实验的 CNN 模型没有包含 GN 和 RB 模块,其具有六层结构,第一层和第二层为两个卷积层,第三层为池化层,第四层和第五层为全连接层,最后一层为 Sigmoid 激活函数. CNN 模型处理 P300 数据的核心在于利用卷积和池化层提取时空特征,然后通过全连接层进行分类,同时使用适当的损失函数和优化器进行参数调整,以实现对比 P300 信号的准确识别.

前四种对比算法使用 sklearn 机器学习库完成模型的搭建,采用十折交叉验证训练模型. 所提模型和消融实验 CNN 模型的实验平台基于深度学习框架 Pytorch 搭建,网络模型由 NVIDIA 3070 进行训练,采用 Adam 优化器优化训练过程,初始学习率设置为 0.0001,迭代训练 1000 轮. 采用的数据为 P300 与非 P300 信息,标签信息为 99 与 0,数据长度选取刺激时刻至 600 ms 的数据. GN 参与求梯度和迭代的拉伸和偏移参数分别初始化为 0 和 1. 采用十折交叉验证,同时将数据集中的样本顺序随机打乱以消除数据的顺序性,随机种子设置为 42.

2.3 模型评估指标 采用分类精度 (Accuracy, Acc)、曲线下面积 (Area under Curve, AUC)、精确率 (Precision, P)、召回率 (Recall, R)、 F_1 -score 来评估模型的性能,其中精确率、召回率、 F_1 -score 的计算如式(12~14)所示:

$$P = \frac{TP}{TP + FP} \quad (12)$$

$$R = \frac{TP}{TP + FN} \quad (13)$$

$$F_1\text{-score} = 2 \frac{R \times P}{R + P} \quad (14)$$

精确率是所有样本中的真阳性样本被标识为阳性的比例,召回率是从真阳性样本中检测到的阳性样本的比例,其中 P 和 R 会相互影响. 如果检测算法理想,这两个指标都很高,但通常很难同时优化它们,一个很高时另一个会很低,所以选择 F_1 -score 作为它们的组合指标. 另外,还采用接收者操作特性曲线 (Receiver Operating Characteristic Curve, ROC) 和其曲线下的面积 (AUC) 来评估本研究中的模型性能.

3 实验结果和分析

P300 响应是解码 P300 拼写器的关键,高效的解码算法能提升拼写器的字符识别率,通过实验来对比现有算法和所提模型的多项性能指标.

消融实验将提出的融入 GN 和 RB 的 GNRBNet 模型与传统的 CNN 模型进行对比,实验中将 GN 和 RB 视为一个组件,所有模型的训练次数均为 1000 轮,实验结果如图 4 所示,图中的红色曲线表示训练损失,蓝色曲线表示测试精度. 由图可见,随着训练轮数的增加,GNRBNet 模型的训练损失在前 200 轮训练中快速下降,并在 1000 轮时收敛,证明其可以快速训练和收敛,其平均测试精度为 96%. 传统 CNN 模型的损失曲线没有随着训练轮数的增加而持续下降,最终停留在 0.25 左右,在第 350 轮时接近最终的测试精度,其平均测试精度只有 90%.

从实验结果可以看到,和传统 CNN 模型相比,GNRBNet 模型的测试精度更高,其曲线的上升更快,证明 GNRBNet 模型能学习到更多的重要特征;GNRBNet 模型的损失下降更快并能快速收敛,证明模型中优化均值和方差的变换操作和特征重用发挥了关键的作用.

除了准确率和损失函数之外,还采用精确率、召回率、 F_1 -score 以及曲线下面积 AUC 作为分类性能的度量指标. 在对比实验中采用相同数据长度的 P300 数据输入模型进行对比训练,不同分类




图 4 所提模型的训练损失(红色)和测试准确率(蓝色)

Fig. 4 Training loss (red) and test accuracy (blue) of the proposed model

模型的性能指标对比如表 1 所示. 由表可见, 对比算法中性能最好的是 Xdown+RegLDA, 性能最差的为 ERP+MDM. 和传统的单特征机器学习算法相比, 所提的 GNRBNet 模型的多个评估指标均优于对比算法, 表现最优, 其准确率为 96%, 精确率为 91%, 召回率为 93%, F_1 -score 为 0.89.

表 1 不同分类模型的性能指标对比

Table 1 Performance indicators of different classification models

模型	准确率	精确率	召回率	F_1 -score
ERP+TS	84%	81%	84%	0.81
ERP+MDM	72%	82%	72%	0.75
Xdown+RegLDA	85%	83%	85%	0.83
Xdown+MDM	69%	81%	69%	0.73
ERP+RegLDA	83%	80%	83%	0.80
CNN	90%	89%	76%	0.80
GNRBNet	96%	91%	93%	0.89

采用交叉验证的方式计算模型的 AUC 来评估模型的性能, 结果如图 5 所示, 图中的误差棒展示了不同模型的 AUC 在 95% 置信区间内的平均值范围. 由图可见, ERP+TS, ERP+MDM 和 ERP+RegLDA 的 AUC 接近 0.8, 高于其他对比算法. 此外, 以上对比算法的 t 检验分析显示, ERP+MDM 与 Xdown+RegLDA 对比存在显著差异 ($p=0.036, t=-2.265$), ERP+MDM 与 ERP+RegLDA 对比存在显著差异 ($p=0.040, t=-2.208$), Xdown+RegLDA 与 Xdown+MDM 对比存在显著差异 ($p=0.025, t=-2.435$), Xdown+

MDM 与 ERP+RegLDA 对比存在显著差异 ($p=0.027, t=-2.391$), CNN 与 ERP+RegLDA 对比存在显著差异 ($p=0.021, t=-2.231$), CNN 与所提的 GNRBNet 模型对比存在显著差异 ($p=0.038, t=-2.216$). 图 6 展示了 GNRBNet 模型的 AUC, 统计分析发现 GNRBNet 与对比模型存在显著差异 ($p<0.05$), 证明其性能优于对比算法, 能更准确地解码 P300.




图 5 复现对比算法的 AUC

Fig. 5 AUC of reproduced comparative algorithms




图 6 所提的 GNRBNet 模型的 AUC

Fig. 6 AUC of the proposed GNRBNet model

前面的实验已经验证了GNRBNet模型在EEG信号P300分类中的有效性,为了研究模型解码准确率与受试者之间的关系并进一步验证GNRBNet模型的性能,在保持实验条件不变的前提下对所有受试者进行分类对比.表2展示了将不同算法应用于解码受试者P300的分类精度.由表可知,与对比算法相比,GNRBNet模型能更好地处理P300时间序列数据,准确率也更高.因为引入GN与RB的改进模型能从多尺度自适应地提取P300信号的特征,可以有效地处理数据分布的不规则性,提高模型训练的稳定性 and 效率.和传统人工提取特征的方法相比,GNRBNet模型在特征提取、特征选择或分类器设计等方面均有改进,能学习多种特征,使其在处理P300数据时有更好的性能,引入的GN与RB能让模型更深而且不容易过拟合,还能更快地收敛到最优解.

表2 不同算法解码不同受试者P300分类精度的对比

Table 2 Accuracy in decoding P300 with different subjects by different algorithms

模型	ERP+ TS	ERP+ MDM	Xdawn+ RegLDA	Xdawn+ MDM	ERP+ RegLDA	CNN	GNRB- Net
S1	83%	69%	84%	69%	82%	92%	95%
S2	85%	73%	81%	74%	83%	91%	97%
S3	82%	67%	81%	69%	83%	89%	96%
S4	82%	66%	88%	63%	85%	88%	95%
S5	86%	74%	88%	72%	84%	91%	98%
S6	81%	62%	82%	62%	80%	88%	92%
S7	83%	73%	83%	64%	82%	87%	91%
S8	86%	67%	81%	66%	84%	85%	98%
S9	82%	69%	82%	68%	79%	90%	94%
S10	89%	77%	87%	74%	86%	91%	95%

4 讨论

CNN具有出色的特征提取能力和非线性拟合能力,使其成为处理P300信号的有力工具.本文提出的GNRBNet模型采用GN和RB结合CNN的算法,对空间特征十分敏感,能有效地提取P300特征.在数据充足的情况下能取得出色的分类精度,为P300信号分类和识别任务带来了更高的效率和准确性.实验结果显示,GNRBNet模型的分类准确率为96%,AUC为0.8.

模块组件GN在训练过程中对每个小批量数据进行归一化,可以起到一定的正则化作用,加速模型的收敛速度,缓解梯度消失和爆炸问题,使网络能更快地收敛到最优解.GN还可以减少内部协变量偏移,减少模型对数据分布的依赖,使模型对参数初始化不敏感,提高了模型的稳定性.

模块组件RB可以使梯度在反向传播时更稳定,帮助训练数据在网络中更快地传播,进一步加速收敛.通过学习残差,模型更深而且不容易过拟合,因为它允许网络学习残差,而不是完全依赖前面的层,所以更容易捕捉数据的细微特征.

GN和RB结合的方式使CNN可以自动提取特征,并且提取的特征能更容易地反向传播到前层,使每一层网络的学习目标更接近一个恒等映射.这种方式可以避免因网络的层数和深度的增加而面临的问题,使模型能更轻松地进行更深的网络结构,从而实现更高的性能^[27].

当前的研究主要集中在单目标字符的响应识别上,未来将专注于提高多目标字符识别的准确率,将所提模型应用于改进的多目标P300拼写器中,以提高P300拼写器的信息传输速率,从而扩展P300拼写器的应用场景,使其在实际应用中更加可靠和有效.

5 结论

针对目前P300数据需多次通道叠加平均、数据量小、特征提取困难等问题,本文将GN和RB与CNN算法相结合,建立了一种高效的P300信号检测模型.该模型能自动提取不需过多预处理的P300数据中的多尺度的特征,并通过多分支残差RB组件来防止模型的过拟合,在此前提下学习到更多的细微特征.GN组件能将训练数据划分为小批量数据并进行归一化,可以起到一定的正则化作用,加快模型的训练收敛速度.和传统的机器学习算法相比,该模型分类准确率为0.96,性能更优.

参考文献

- [1] dos Santos E M, San - Martin R, Fraga F J. Comparison of subject - independent and subject - specific EEG - based BCI using LDA and SVM

- classifiers. *Medical & Biological Engineering & Computing*, 2023, 61(3): 835—845.
- [2] Oralhan Z. A new paradigm for region-based P300 speller in brain computer interface. *IEEE Access*, 2019, 7: 106618—106627.
- [3] Kropotov J D, Ponomarev V A, Pronina M V. The P300 wave is decomposed into components reflecting response selection and automatic reactivation of stimulus - response links. *Psychophysiology*, 2024: e14578, DOI:10.1111/psyp.14578.
- [4] Kundu S, Ari S. P300 based character recognition using convolutional neural network and support vector machine. *Biomedical Signal Processing and Control*, 2020, 55: 101645.
- [5] Pan J H, Wang L, Huang H Y, et al. A hybrid brain-computer interface combining P300 potentials and emotion patterns for detecting awareness in patients with disorders of consciousness. *IEEE Transactions on Cognitive and Developmental Systems*, 2023, 15(3): 1386—1395.
- [6] Liu X, Xie Q S, Lv J, et al. P300 event-related potential detection using one-dimensional convolutional capsule networks. *Expert Systems with Applications*, 2021, 174: 114701.
- [7] Sahay R, Brinton C G. Robust subject-independent P300 waveform classification via signal pre-processing and deep learning. *IEEE Access*, 2021, 9: 87579—87591.
- [8] Shim M, Jin M J, Im C H, et al. Machine-learning-based classification between post-traumatic stress disorder and major depressive disorder using P300 features. *NeuroImage: Clinical*, 2019, 24: 102001.
- [9] 刘邈, 林超, 韩锦, 等. 基于 P300 特征的脑-机接口解码算法研究综述. *信号处理*, 2023, 39(8): 1367—1385. (Liu M, Lin C, Han J, et al. A review of brain-computer interface decoding algorithms based on P300 features. *Journal of Signal Processing*, 2023, 39(8): 1367—1385.)
- [10] Schembri P, Pelc M, Ma J X. The effect that auxiliary taxonomized auditory distractions have on a P300 speller while utilising low fidelity equipment// 2019 11th Computer Science and Electronic Engineering. Colchester, UK: IEEE, 2019: 118—123.
- [11] Li B W, Lin Y F, Gao X R, et al. Enhancing the EEG classification in RSVP task by combining interval model of ERPs with spatial and temporal regions of interest. *Journal of Neural Engineering*, 2021, 18(1): 016008.
- [12] Santamaria - Vázquez E, Martínez - Cagigal V, Vaquerizo - Villar F, et al. EEG-inception: A novel deep convolutional neural network for assistive ERP-based brain-computer interfaces. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2020, 28(12): 2773—2782.
- [13] Schirmermeister R T, Springenberg J T, Fiederer L D J, et al. Deep learning with convolutional neural networks for EEG decoding and visualization. *Human Brain Mapping*, 2017, 38(11): 5391—5420.
- [14] Abibullaev B, Zollanvari A. A systematic deep learning model selection for P300-based brain-computer interfaces. *IEEE Transactions on Systems, Man, and Cybernetics: Systems*, 2022, 52(5): 2744—2756.
- [15] Dağ I, Dui L G, Ferrante S, et al. Leveraging deep learning techniques to improve P300-based brain computer interfaces. *IEEE Journal of Biomedical and Health Informatics*, 2022, 26(10): 4892—4902.
- [16] Keshavarzi M, Choidealbha Á N, Attaheri A, et al. Decoding speech information from EEG data with 4-, 7- and 11-month-old infants: Using convolutional neural network, mutual information-based and backward linear models. *Journal of Neuroscience Methods*, 2024, 403: 110036.
- [17] Völker M, Schirmermeister R T, Fiederer L D J, et al. Deep transfer learning for error decoding from non-invasive EEG// 2018 6th International Conference on Brain-Computer Interface (BCI). Gangwon, Korea (South): IEEE, 2018: 1—6.
- [18] Li F, Li X Y, Wang F, et al. A novel P300 classification algorithm based on a principal component analysis-convolutional neural network. *Applied Sciences*, 2020, 10(4): 1546.
- [19] Oralhan Z. 2 Stages-region-based P300 speller in brain-computer interface. *IETE Journal of Research*, 2019, 65(6): 740—748.
- [20] 于鸿伟, 谢俊, 何柳诗, 等. 基于卷积神经网络和支持向量机的事件相关电位识别方法. *西安交通大学学报*, 2021, 55(12): 47—54. (Yu H W, Xie J, He L S, et al. An event-related potential recognition method based on convolutional neural network and

- support vector machine. *Journal of Xi'an Jiaotong University*, 2021, 55(12): 47—54.)
- [21] Hamilton H K, Mathalon D H, Ford J M. P300 in schizophrenia: Then and now. *Biological Psychology*, 2024, 187: 108757.
- [22] Jang K I, Kim S, Chae J H, et al. Machine learning-based classification using electroencephalographic multi-paradigms between drug-naive patients with depression and healthy controls. *Journal of Affective Disorders*, 2023, 338: 270—277.
- [23] Bae K Y, Kim D W, Im C H, et al. Source imaging of P300 auditory evoked potentials and clinical correlations in patients with posttraumatic stress disorder. *Progress in Neuro - Psychopharmacology and Biological Psychiatry*, 2011, 35(8): 1908—1917.
- [24] 夏逸. 基于黎曼几何的P300脑电信号迁移学习分类算法研究. 硕士学位论文. 长沙: 长沙理工大学, 2020, DOI: 10.26985/d.cnki.gcsjc.2020.000713. (Xia Y. Research on P300 - EEG transfer learning classification algorithm based Riemann geometry. Master Dissertation. Changsha: Changsha University of Science & Technology, 2020, DOI: 10.26985/d.cnki.gcsjc.2020.000713.)
- [25] Barthélemy Q, Chevallier S, Bertrand-Lalo R, et al. End-to-end P300 BCI using Bayesian accumulation of Riemannian probabilities. *Brain - Computer Interfaces*, 2023, 10(1): 50—61.
- [26] 曹帅, 吴畏. 基于xDAWN和降噪自编码器的事件相关电位分类. 中国科技论文, 2018, 13(24): 2829—2833. (Cao S, Wu W. Classifying the event-related potentials using xDAWN and denoising auto-encoder. *China Sciencepaper*, 2018, 13(24): 2829—2833.)
- [27] Farhat N. Classification of P300 from non-invasive EEG signal using convolutional neural network. Master Dissertation. Fort Collins: Colorado State University, 2022.

(责任编辑 杨可盛)